

IIC2685 Robótica Móvil I – 2022

Capítulo 4.1

Fundamentos de Robótica Probabilística

Profesor: Gabriel Sepúlveda V.
grsepulveda@ing.puc.cl

Agenda


- Conceptos de probabilidades para robótica móvil
 - Probabilidades (repaso)
 - Regla de Bayes
- Fundamentos de Robótica Probabilística
 - Modelo oculto de Markov (HMM)
 - Filtros bayesianos
- Todos los capítulos relacionados con robótica probabilística que trataremos en este curso, estarán basados en:
 - “Probabilistic Robotics” (Thrun, Burgard y Fox)

Probabilidades

- Probabilidad: medida de la **certidumbre** asociada a la ocurrencia de un suceso al realizar un experimento de naturaleza aleatoria.
- Un **experimento** está compuesto por dos etapas:
 - *Procedimiento* (ej: lanzar una moneda)
 - *Observaciones* (ej: observar que lado de la moneda queda hacia arriba)
- Resultado: Un resultado de un experimento es cualquier posible **observación** de ese experimento (ej: *salió cara, salió sello*).


Probabilidades

- Espacio muestral: El espacio muestral de un experimento es el **conjunto de todos los posibles resultados** que cumplen con:
 - Estar en su mayor estado de granularidad
 - Ser mutuamente excluyentes
 - Ser colectivamente exhaustivos




Probabilidades

- Evento: Un evento es un **conjunto de resultados** de un experimento
 - Ej: Lanzar un dado y que el resultado sea mayor o igual a 4 = $\{ 4, 5, 6 \}$



Probabilidades

- Espacio de eventos: Un espacio de eventos es un conjunto de eventos que cumplen con:
 - Ser mutuamente excluyentes
 - Colectivamente exhaustivos



Probabilidades

Axiomas de Probabilidad

Una medida de probabilidad $P[\cdot]$ es una función que mapea **eventos** en el **espacio muestral** a número reales que representan su nivel de **certidumbre**, tal que:


- **Axioma 1:** Para todo evento A , $P[A] \geq 0$
- **Axioma 2:** $P[S] = 1$
- **Axioma 3:** Para cualquier colección contable de eventos **mutuamente excluyentes** A_1, A_2, \dots , se tiene que:

$$P[A_1 \cup A_2 \cup \dots] = P[A_1] + P[A_2] + \dots$$

Probabilidades

Para eventos **NO mutuamente excluyentes**, se tiene que:

$$P[A \cup B] = P[A] + P[B] - P[A \cap B]$$



Probabilidades


- Relación entre **evento** y su **complemento** a través de los axiomas:

$$P[A \cup A^c] = P[A] + P[A^c] - P[A \cap A^c]$$

$$P[S] = P[A] + P[A^c] - P[\emptyset]$$

$$1 = P[A] + P[A^c]$$

$$P[A^c] = 1 - P[A]$$



Probabilidades



Variable Aleatoria

- Una variable aleatoria consiste en:
 - Un experimento con **medida de probabilidad $P[\cdot]$** definida en un espacio muestral S
 - Una función que **asigna un número real a un resultado** en el espacio muestral S del experimento

Probabilidades

Variable Aleatoria

- Una variable aleatoria X puede ser:
 - Variable discreta: Función de Masa de Probabilidad (*PMF*)
$$P[X = x] \quad o \quad P_X(x)$$
 - Variable continua: Función de Densidad de Probabilidad (*PDF*)
$$f[X = x] \quad o \quad f_X(x)$$



Probabilidades

- **Axiomas caso discreto:** Para una variable aleatoria X con PMF $P_X(x)$ y rango $S_X = \{x_1, x_2, \dots\}$:
 - Para todo x , $P_X(x) \geq 0$
 - $\sum_{x \in S_X} P_X(x) = 1$
 - Para cualquier evento $B \subset S_X$ la probabilidad de que X se encuentre en el conjunto B es:

$$P[B] = \sum_{x \in B} P_X(x)$$

Probabilidades


- **Axiomas caso continuo:** Para una variable aleatoria continua X con función de densidad de probabilidad $f_X(x)$:
 - Para todo x , $f_X(x) \geq 0$
 - $\int_{-\infty}^{\infty} f_X(x) dx = 1$
 - Función de Distribución Acumulada (*CDF*): $F_X(x) = \int_{-\infty}^x f_X(u) du$

Probabilidades

Probabilidad Conjunta

- Probabilidad de ocurrencia de resultados comunes a dos o más eventos

$$P[X = x \cap Y = y] = P[x, y]$$




Probabilidades

Probabilidad Condicional

- Probabilidad de que el evento X ocurra dado que se supone (asume) que Y ocurre

$$P[x|y] = \frac{P[x, y]}{P[y]}$$



Probabilidades

Probabilidad Condicional

$$P[x|y] = \frac{P[x, y]}{P[y]}$$

- ¿ Si X es independiente de Y ?

$$P[x, y] = P[x] \cdot P[y]$$

$$P[x|y] = P[x]$$

- También es posible obtener $P[y|x]$

$$P[y|x] = \frac{P[x, y]}{P[x]}$$

Probabilidades

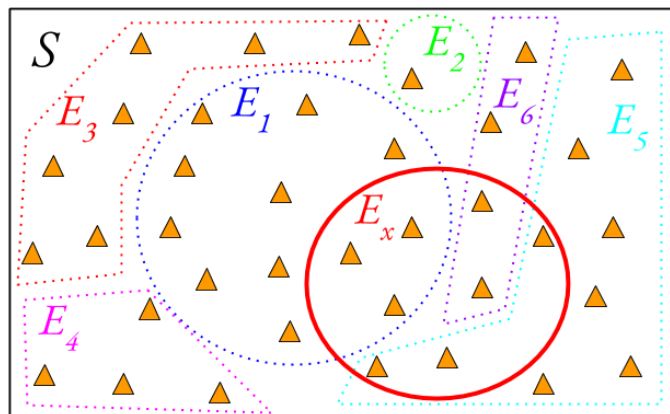
Probabilidad Marginal

- Caso discreto: Sean X e Y variables aleatorias con PMF $P_{X,Y}(x, y)$:

$$P_X(x) = \sum_y P_{X,Y}(x, y) \qquad P_Y(y) = \sum_x P_{X,Y}(x, y)$$

- Caso continuo: Sean X e Y variables aleatorias con PDF $f_{X,Y}(x, y)$:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy \qquad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx$$



Probabilidades


Ley de Probabilidad Total

- Caso discreto: Sean X e Y variables aleatorias con PMF $P_{X,Y}(x, y)$:

$$P_X(x) = \sum_y P_{X|Y}(x|y) \cdot P_Y(y)$$

- Caso continuo: Sean X e Y variables aleatorias con PDF $f_{X,Y}(x, y)$:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X|Y}(x|y) \cdot f_Y(y) dy$$



Regla de Bayes

$$P(x|y) = \frac{P(x, y)}{P(y)}$$

$$P(y|x) = \frac{P(x, y)}{P(x)}$$

REGLA DE BAYES

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)} = \frac{P(x|y)P(y)}{\sum_{y_i} P(x|y_i)P(y_i)}$$

posterior = $\frac{\text{likelihood} \times \text{prior}}{\text{evidence}}$

Regla de Bayes

Ejemplo

- Cierto artículo se manufactura en tres fábricas Fab1, Fab2 y Fab3. Se sabe que Fab2 y Fab3 producen el mismo número de artículos, mientras que Fab1, produce el doble de artículos que Fab2 y que Fab3. Se sabe también que el 2% de los artículos producidos por las dos primeras es defectuoso (D), mientras que el 4% de los manufacturados por la tercera es defectuoso. Todos los artículos producidos por las tres fábricas se colocan en una fila y se escoge uno al azar.*

$D = \{\text{artículo defectuoso}\}$

$F1 = \{\text{artículo fabricado en Fab1}\}$

$F2 = \{\text{artículo fabricado en Fab2}\}$

$F3 = \{\text{artículo fabricado en Fab3}\}$

Regla de Bayes

Ejemplo

¿Cuál es la probabilidad de que este artículo sea defectuoso ?

Causa (*fábrica con falla*)  Efecto (*artículo defectuoso*)

$$\begin{aligned} P[D] &= P[D \cap F1] + P[D \cap F2] + P[D \cap F3] \\ &= P[D|F1] \cdot P[F1] + P[D|F2] \cdot P[F2] + P[D|F3] \cdot P[F3] \\ &= 0.02 \cdot 0.5 + 0.02 \cdot 0.25 + 0.04 \cdot 0.25 \\ &= 0.025 \end{aligned}$$

Regla de Bayes

Ejemplo

Supongamos que se escoge un artículo del total y se encuentra uno defectuoso. ¿Cuál es la probabilidad de que se haya producido en la fábrica Fab1 ?

Efecto (*artículo defectuoso*)  Causa (*fábrica con falla*)

$$\begin{aligned} P[F1|D] &= (P[D|F1] \cdot P[F1]) / P[D] \\ &= (0.02 \cdot 0.5) / 0.025 \\ &= 0.4 \end{aligned}$$

Probabilidades

- Bayes con conocimiento previo

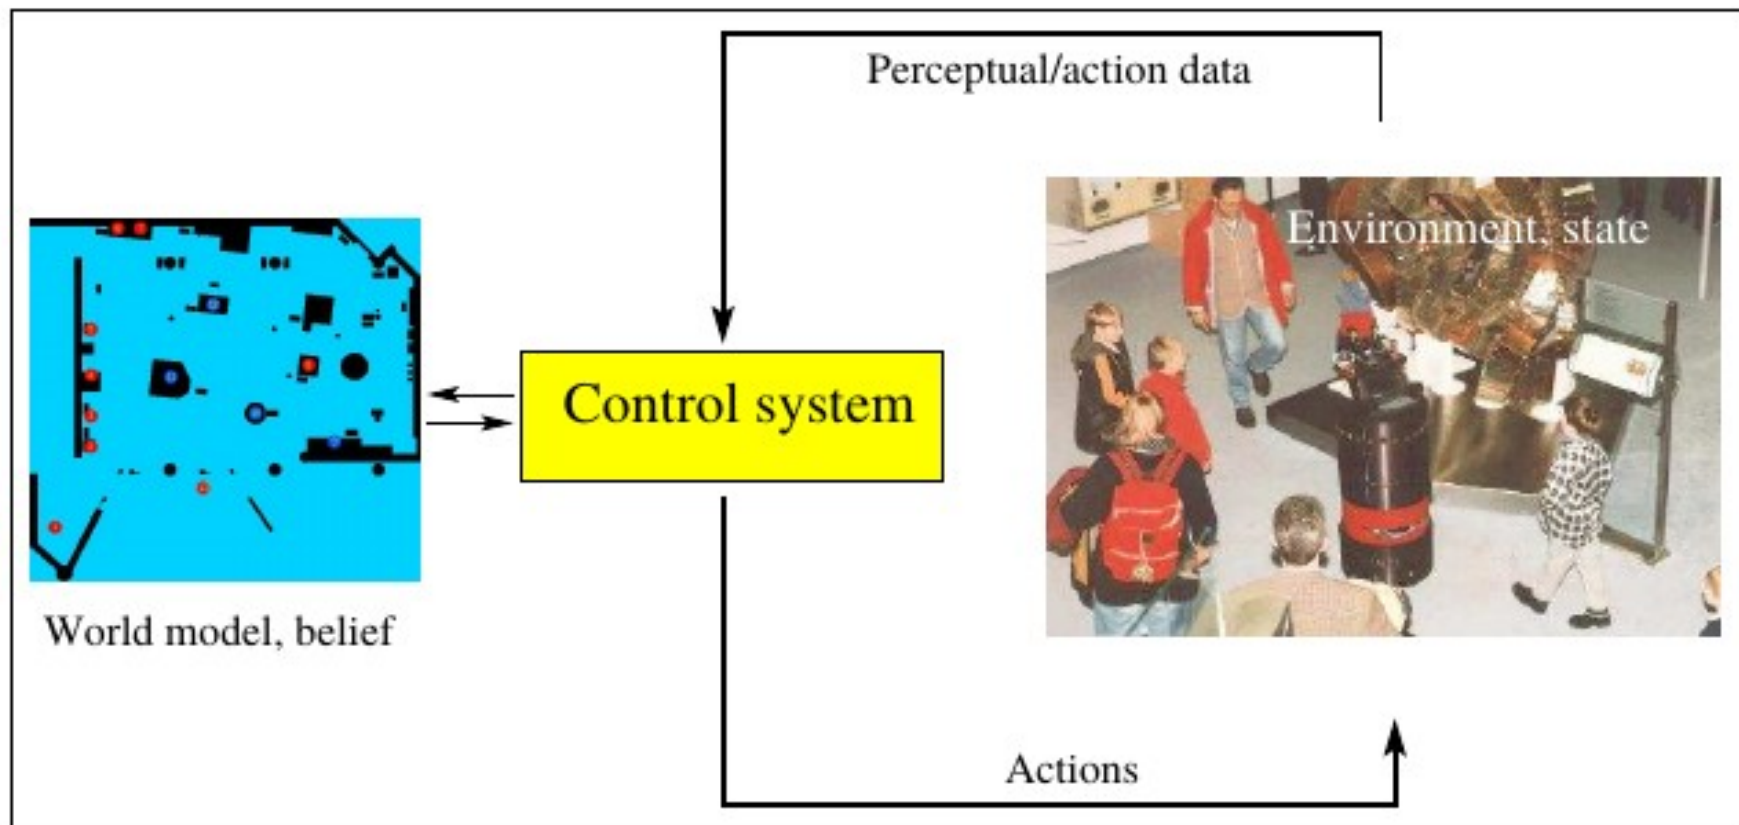
$$P(y|x, z) = \frac{P(x|y, z)P(y|z)}{P(x|z)}$$

- Independencia condicional

$$P(x, y|z) = P(x|z)P(y|z)$$


Robótica Probabilística

- Modelo de interacción de robot con el ambiente (“mundo”)



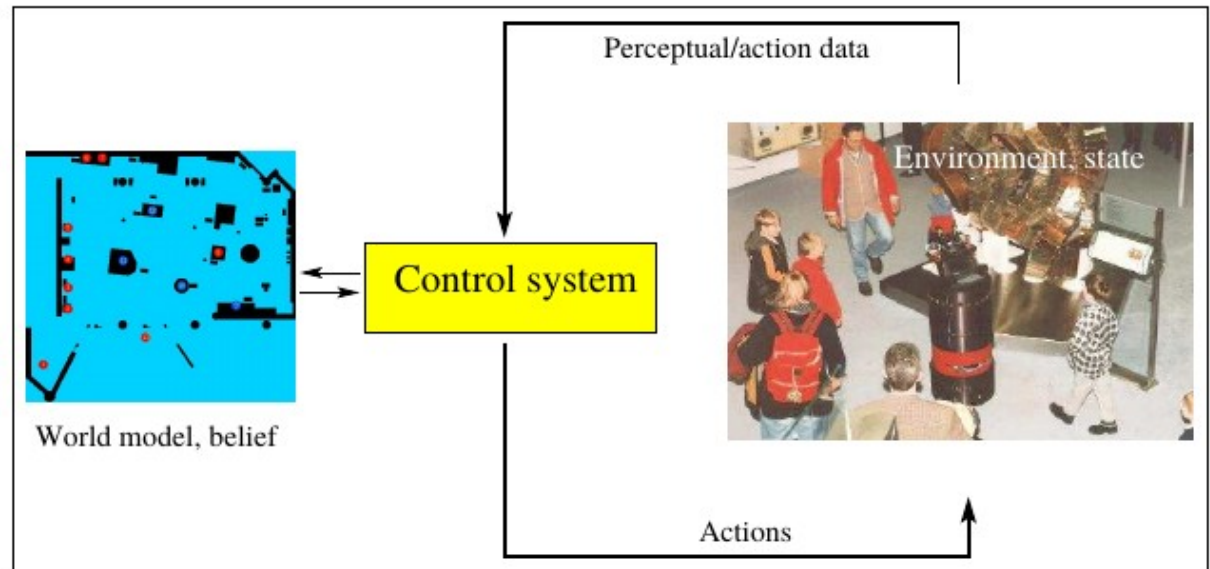
Robótica Probabilística

- **Objetivo:** estimación del estado actual del ambiente a partir de los sensores
- Estado del ambiente
 - Dinámicos
 - Estáticos
- Variables del estado: X_t
 - Pose
 - Velocidad
 - Estado de actuadores
 - Estado de sensores
 - Ubicación y velocidad de objetos circundantes
 - etc.



Robótica Probabilística


- Medición de sensores: \mathbf{z}_t
 - Parcial
 - Indirecta
 - Ruidosa/Corrupta
- Acciones de Control: \mathbf{u}_t
 - Movimiento
 - Manipulación
 - Inacción



Robótica Probabilística

Ejemplo

- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un *score*




Robótica Probabilística

Ejemplo

- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score

$$p[X_0 = \textit{open}] = 0.5$$

$$p[X_0 = \textit{closed}] = 0.5$$



Robótica Probabilística

Ejemplo


- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score

$$p[X_0 = \textit{open}] = 0.5$$

$$p[X_0 = \textit{closed}] = 0.5$$

$$p[Z_t = \textit{sense_open} | X_t = \textit{open}] = 0.6$$

$$p[Z_t = \textit{sense_closed} | X_t = \textit{closed}] = 0.8$$



Robótica Probabilística


Ejemplo

- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score

$$p[X_0 = \textit{open}] = 0.5$$
$$p[X_0 = \textit{closed}] = 0.5$$

$$p[Z_t = \textit{sense_open} | X_t = \textit{open}] = 0.6$$
$$p[Z_t = \textit{sense_closed} | X_t = \textit{closed}] = 0.8$$

$$p[X_0 = \textit{open} | Z_0 = \textit{sense_open}] = ?$$
$$p[X_0 = \textit{closed} | Z_0 = \textit{sense_open}] = ?$$



Robótica Probabilística

Ejemplo


- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score

$$p[X_0 = \textit{open}] = 0.5$$

$$p[X_0 = \textit{closed}] = 0.5$$

$$p[Z_t = \textit{sense_open} | X_t = \textit{open}] = 0.6$$

$$p[Z_t = \textit{sense_closed} | X_t = \textit{closed}] = 0.8$$



$$p[X_0 = \textit{open} | Z_0 = \textit{sense_open}] = \frac{p[Z_0 = \textit{sense_open} | X_0 = \textit{open}] \cdot p[X_0 = \textit{open}]}{p[z_0 = \textit{sense_open}]}$$

Robótica Probabilística

Ejemplo


- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score

$$p[X_0 = \textit{open}] = 0.5$$

$$p[X_0 = \textit{closed}] = 0.5$$

$$p[Z_t = \textit{sense_open} | X_t = \textit{open}] = 0.6$$

$$p[Z_t = \textit{sense_closed} | X_t = \textit{closed}] = 0.8$$



$$\begin{aligned} p[Z_0 = \textit{sense_open}] = & p[Z_0 = \textit{sense_open} | X_0 = \textit{open}] \cdot p[X_0 = \textit{open}] \\ & + p[Z_0 = \textit{sense_open} | X_0 = \textit{closed}] \cdot p[X_0 = \textit{closed}] \end{aligned}$$

Robótica Probabilística

Ejemplo


- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score

$$p[X_0 = \textit{open}] = 0.5$$

$$p[X_0 = \textit{closed}] = 0.5$$

$$p[Z_t = \textit{sense_open} | X_t = \textit{open}] = 0.6$$

$$p[Z_t = \textit{sense_closed} | X_t = \textit{closed}] = 0.8$$



$$\begin{aligned} p[Z_0 = \textit{sense_open}] &= p[Z_0 = \textit{sense_open} | X_0 = \textit{open}] \cdot p[X_0 = \textit{open}] \\ &\quad + p[Z_0 = \textit{sense_open} | X_0 = \textit{closed}] \cdot p[X_0 = \textit{closed}] \\ &= 0.6 \cdot 0.5 + 0.2 \cdot 0.5 \\ &= 0.4 \end{aligned}$$

Robótica Probabilística

Ejemplo


- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score

$$p[X_0 = \textit{open}] = 0.5$$

$$p[X_0 = \textit{closed}] = 0.5$$

$$p[Z_t = \textit{sense_open} | X_t = \textit{open}] = 0.6$$

$$p[Z_t = \textit{sense_closed} | X_t = \textit{closed}] = 0.8$$



$$\begin{aligned} p[X_0 = \textit{open} | Z_0 = \textit{sense_open}] &= \frac{p[Z_0 = \textit{sense_open} | X_0 = \textit{open}] \cdot p[X_0 = \textit{open}]}{p[z_0 = \textit{sense_open}]} \\ &= \frac{0.6 \cdot 0.5}{0.4} \\ &= 0.75 \end{aligned}$$

Robótica Probabilística


Ejemplo

- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score

$$p[X_0 = \textit{open}] = 0.5$$
$$p[X_0 = \textit{closed}] = 0.5$$

$$p[Z_t = \textit{sense_open} | X_t = \textit{open}] = 0.6$$
$$p[Z_t = \textit{sense_closed} | X_t = \textit{closed}] = 0.8$$

$$p[X_0 = \textit{open} | Z_0 = \textit{sense_open}] = 0.75$$
$$p[X_0 = \textit{closed} | Z_0 = \textit{sense_open}] = 0.25$$



Robótica Probabilística


- Para una medición particular z_t , el denominador es solo un **factor de normalización**

$$\eta = \left(\sum_{x_i} P(z|x_i) \cdot P(x_i) \right)^{-1} \quad P(x_i|z) = \eta \cdot P(z|x_i) \cdot P(x_i)$$

- Bayes en la práctica
 - Calcular el *likelihood* para cada x_i
 - Multiplicar cada *likelihood* por el conocimiento previo de x_i
 - Sumar el resultado anterior para calcular η

Robótica Probabilística

- Hasta ahora hemos encontrado una metodología para modelar las mediciones, pero ...
- ¿Cómo podemos incorporar las acciones u_t , para junto a las mediciones z_t , obtener el estado (*belief*) x_t ?




Modelo Oculto de Markov (HMM)

- Supongamos ahora que tenemos una secuencia de acciones $u_{1:t}$, observaciones $z_{1:t}$ y sus respectivos estados del mundo $x_{0:t}$, tal que:

$$U_{1:t} = U_1, U_2 \dots, U_t$$

$$Z_{1:t} = Z_1, Z_2 \dots, Z_t$$

$$X_{0:t} = X_0, X_1 \dots, X_t$$



- Es posible definir:
 - *Modelo de acción (o transición de estado):*

$$P[x_t | x_{0:t-1}, z_{1:t-1}, u_{1:t}]$$

- *Modelo de sensor:*

$$P[z_t | x_{0:t}, z_{1:t-1}, u_{1:t}]$$

Modelo Oculto de Markov (HMM)

- Aplicando la propiedad de **independencia condicional**, tenemos:

- *Modelo de acción (o transición de estado):*

$$P[x_t | x_{0:t-1}, z_{1:t-1}, u_{1:t}] = P[x_t | x_{t-1}, u_t]$$

- *Modelo de sensor:*

$$P[z_t | x_{0:t}, z_{1:t-1}, u_{1:t}] = P[z_t | x_t]$$

Modelo Oculto de Markov (HMM)

- Aplicando la propiedad de **independencia condicional**, tenemos:

- *Modelo de acción (o transición de estado):*


$$P[x_t | x_{0:t-1}, z_{1:t-1}, u_{1:t}] = P[x_t | x_{t-1}, u_t]$$

- *Modelo de sensor:*

$$P[z_t | x_{0:t}, z_{1:t-1}, u_{1:t}] = P[z_t | x_t]$$

- Podemos concluir que:

El futuro depende del pasado solo a través del presente



Robótica Probabilística

Filtros Bayesianos

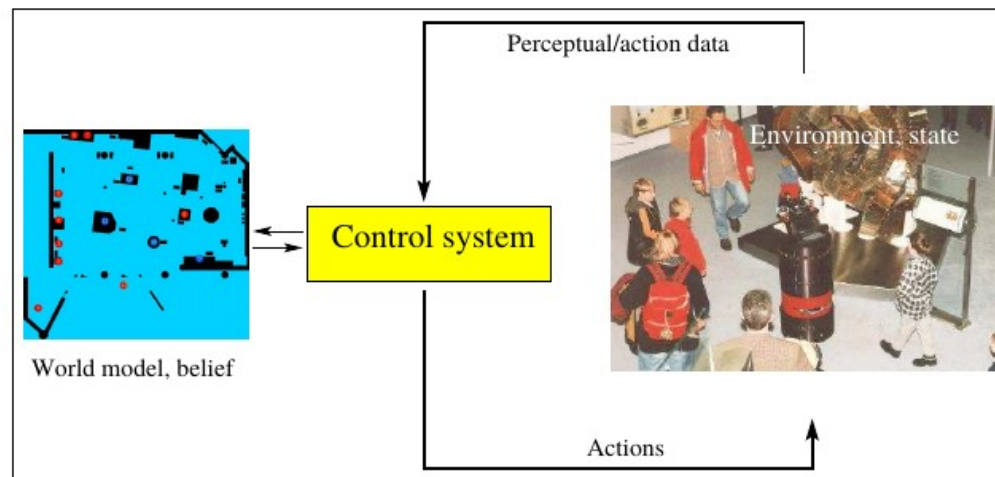
- Queremos estimar el estado x_t de un mundo dinámico
- Contamos con:
 - Acciones y observaciones: $u_1, z_1, \dots, u_t, z_t$
 - Modelo de acción: $P[x_t | x_{t-1}, u_t]$
 - Modelo de sensor: $P[z_t | x_t]$
 - Conocimiento previo (*prior*): $P[x_t]$

Robótica Probabilística

Filtros Bayesianos

- ¿Qué buscamos ?
 - Estimar la distribución *posterior* $P[x_t | u_1, z_1, \dots, u_t, z_t]$
 - Ésta es comúnmente llamada *belief*, y representa el conocimiento interno que posee el robot acerca del estado del ambiente:

$$Bel[X_t] = P[x_t | u_1, z_1, \dots, u_t, z_t]$$



Robótica Probabilística

Filtros Bayesianos

- ¿Qué buscamos ?
 - Estimar la distribución *posterior* $P[x_t | u_1, z_1, \dots, u_t, z_t]$
 - Ésta es comúnmente llamada *belief*, y representa el conocimiento interno que posee el robot acerca del estado del ambiente:

$$Bel[X_t] = P[x_t | u_1, z_1, \dots, u_t, z_t]$$

- Supuestos:
 - Propiedad markoviana en observaciones (observaciones condicionalmente independientes del *pasado*, dado el mundo)
 - Un mundo “estático”
 - Modelos “perfectos”

Robótica Probabilística

Filtros Bayesianos

$$Bel[X_t] = P[x_t | u_1, z_1, \dots, u_t, z_t]$$

Filtros Bayesianos

$$Bel[X_t] = P[x_t | u_1, z_1, \dots, u_t, z_t]$$

Bayes

$$= \eta \cdot P[z_t | u_1, z_1, \dots, u_t, x_t] \cdot P[x_t | u_1, z_1, \dots, u_t]$$

Filtros Bayesianos

$$Bel[X_t] = P[x_t | u_1, z_1, \dots, u_t, z_t]$$

Bayes

$$= \eta \cdot P[z_t | u_1, z_1, \dots, u_t, x_t] \cdot P[x_t | u_1, z_1, \dots, u_t]$$

Markov

$$= \eta \cdot P[z_t | x_t] \cdot P[x_t | u_1, z_1, \dots, u_t]$$

Robótica Probabilística

Filtros Bayesianos

$$Bel[X_t] = P[x_t | u_1, z_1, \dots, u_t, z_t]$$

Bayes

$$= \eta \cdot P[z_t | u_1, z_1, \dots, u_t, x_t] \cdot P[x_t | u_1, z_1, \dots, u_t]$$

Markov

$$= \eta \cdot P[z_t | x_t] \cdot P[x_t | u_1, z_1, \dots, u_t]$$

Probabilidades Totales

$$= \eta \cdot P[z_t | x_t] \cdot \int P[x_t | u_1, z_1, \dots, u_t, x_{t-1}] \cdot P[x_{t-1} | u_1, z_1, \dots, u_t] dx_{t-1}$$

Filtros Bayesianos

$$Bel[X_t] = P[x_t | u_1, z_1, \dots, u_t, z_t]$$

Bayes

$$= \eta \cdot P[z_t | u_1, z_1, \dots, u_t, x_t] \cdot P[x_t | u_1, z_1, \dots, u_t]$$

Markov

$$= \eta \cdot P[z_t | x_t] \cdot P[x_t | u_1, z_1, \dots, u_t]$$

Probabilidades Totales

$$= \eta \cdot P[z_t | x_t] \cdot \int P[x_t | u_1, z_1, \dots, u_t, x_{t-1}] \cdot P[x_{t-1} | u_1, z_1, \dots, u_t] dx_{t-1}$$

Markov

$$= \eta \cdot P[z_t | x_t] \cdot \int P[x_t | u_t, x_{t-1}] \cdot P[x_{t-1} | u_1, z_1, \dots, z_{t-1}] dx_{t-1}$$

Robótica Probabilística

Filtros Bayesianos

$$Bel[X_t] = P[x_t | u_1, z_1, \dots, u_t, z_t]$$

Bayes

$$= \eta \cdot P[z_t | u_1, z_1, \dots, u_t, x_t] \cdot P[x_t | u_1, z_1, \dots, u_t]$$

Markov

$$= \eta \cdot P[z_t | x_t] \cdot P[x_t | u_1, z_1, \dots, u_t]$$

Probabilidades Totales

$$= \eta \cdot P[z_t | x_t] \cdot \int P[x_t | u_1, z_1, \dots, u_t, x_{t-1}] \cdot P[x_{t-1} | u_1, z_1, \dots, u_t] dx_{t-1}$$

Markov

$$= \eta \cdot P[z_t | x_t] \cdot \int P[x_t | u_t, x_{t-1}] \cdot P[x_{t-1} | u_1, z_1, \dots, z_{t-1}] dx_{t-1}$$

$$Bel[x_t] = \eta \cdot P[z_t | x_t] \cdot \int P[x_t | u_t, x_{t-1}] \cdot Bel[x_{t-1}] dx_{t-1}$$

Filtros Bayesianos

```
1:  Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:      for all  $x_t$  do  
3:           $\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:           $bel(x_t) = \eta p(z_t \mid x_t) \overline{bel}(x_t)$   
5:      endfor  
6:      return  $bel(x_t)$ 
```

Robótica Probabilística

Ejemplo


- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score
- Robot no ejecuta acciones (u_t)

$$P[z_t = \textit{sense_open} | x_t = \textit{open}] = 0.6$$

$$P[z_t = \textit{sense_closed} | x_t = \textit{closed}] = 0.8$$

$$P[x_0 = \textit{open}] = \textit{Bel}[x_0 = \textit{open}] = 0.5$$

$$P[x_0 = \textit{closed}] = \textit{Bel}[x_0 = \textit{closed}] = 0.5$$



Robótica Probabilística

Ejemplo

- Estado del mundo (x_t): *open* o *closed*
- Medición (z_t): clasificador que entrega un score
- Robot no ejecuta acciones (u_t)


$$P[z_t = \textit{sense_open} | x_t = \textit{open}] = 0.6$$

$$P[z_t = \textit{sense_closed} | x_t = \textit{closed}] = 0.8$$

$$P[x_0 = \textit{open}] = \textit{Bel}[x_0 = \textit{open}] = 0.5$$

$$P[x_0 = \textit{closed}] = \textit{Bel}[x_0 = \textit{closed}] = 0.5$$

$$\textit{Bel}[x_2 = \textit{open}] = P[x_2 = \textit{open} | u_2 = \textit{do_nothing}, z_2 = \textit{sense_open}] = ?$$



Robótica Probabilística

Ejemplo

```
1:  Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:    for all  $x_t$  do  
3:       $\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:       $bel(x_t) = \eta p(z_t \mid x_t) \overline{bel}(x_t)$   
5:    endfor  
6:    return  $bel(x_t)$ 
```

Robótica Probabilística

Ejemplo

```
1:   Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:     for all  $x_t$  do  
3:        $\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:        $bel(x_t) = \eta p(z_t \mid x_t) \overline{bel}(x_t)$   
5:     endfor  
6:     return  $bel(x_t)$ 
```

$$\begin{aligned}\overline{bel}(X_1 = open) &= p(X_1 = open \mid X_0 = open) * bel(X_0 = open) \\ &\quad + p(X_1 = open \mid X_0 = closed) * bel(X_0 = closed) \\ &= 1 * 0.5 + 0 * 0.5 = 0.5\end{aligned}$$

Robótica Probabilística

Ejemplo

```
1:   Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:     for all  $x_t$  do  
3:        $\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:        $bel(x_t) = \eta p(z_t \mid x_t) \overline{bel}(x_t)$   
5:     endfor  
6:     return  $bel(x_t)$ 
```

$$\begin{aligned}\overline{bel}(X_1 = open) &= p(X_1 = open \mid X_0 = open) * bel(X_0 = open) \\ &\quad + p(X_1 = open \mid X_0 = closed) * bel(X_0 = closed) \\ &= 1 * 0.5 + 0 * 0.5 = 0.5\end{aligned}$$

$$\begin{aligned}bel(X_1 = open) &= p(X_1 = open \mid Z_1 = open) \\ &= \frac{p(Z_1 = open \mid X_1 = open) * \overline{bel}(X_1 = open)}{p(Z_1 = open \mid X_1 = open) * p(X_1 = open) + p(Z_1 = open \mid X_1 = closed) * p(X_1 = closed)} \\ &= \frac{0.6 * 0.5}{0.6 * 0.5 + 0.2 * 0.5} = 0.75\end{aligned}$$

Robótica Probabilística

Ejemplo

```
1:   Algorithm Bayes_filter( $bel(x_{t-1}), u_t, z_t$ ):  
2:     for all  $x_t$  do  
3:        $\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx$   
4:        $bel(x_t) = \eta p(z_t \mid x_t) \overline{bel}(x_t)$   
5:     endfor  
6:     return  $bel(x_t)$ 
```

$$\begin{aligned}\overline{bel}(X_2 = open) &= p(X_2 = open \mid X_1 = open) * bel(X_1 = open) \\ &\quad + p(X_2 = open \mid X_1 = closed) * bel(X_1 = closed) \\ &= 1 * 0.75 + 0 * 0.25 = 0.75\end{aligned}$$

$$\begin{aligned}bel(X_2 = open) &= p(X_2 = open \mid Z_2 = open) \\ &= \frac{p(Z_2 = open \mid X_2 = open) * \overline{bel}(X_2 = open)}{p(Z_2 = open \mid X_2 = open) * p(X_2 = open) + p(Z_2 = open \mid X_2 = closed) * p(X_2 = closed)} \\ &= \frac{0.6 * 0.75}{0.6 * 0.75 + 0.2 * 0.25} = 0.9\end{aligned}$$

Robótica Probabilística

- ¿Qué pasa con $Bel(x_t)$ cuando agregamos mediciones z_t ?

Robótica Probabilística

- ¿Qué pasa con $Bel(x_t)$ cuando agregamos mediciones z_t ?
 - Como vimos en el ejemplo, **aumenta la certeza** !

Robótica Probabilística

- ¿ Qué pasa con $Bel(x_t)$ cuando agregamos mediciones z_t ?
 - Como vimos en el ejemplo, **aumenta la certeza** !
- ¿ Qué pasa con $Bel(x_t)$ cuando agregamos una acción u_t ?
 - Acción efectuada por el robot
 - Acción efectuada por un agente externo
 - Tiempo
 - ... algo que cambie el estado del mundo

Robótica Probabilística

- ¿ Qué pasa con $Bel(x_t)$ cuando agregamos mediciones z_t ?
 - Como vimos en el ejemplo, **aumenta la certeza** !
- ¿ Qué pasa con $Bel(x_t)$ cuando agregamos una acción u_t ?
 - Acción efectuada por el robot
 - Acción efectuada por un agente externo
 - Tiempo
 - ... algo que cambie el estado del mundo
 - **Disminuye la certeza** !

Robótica Probabilística

- ¿ Qué pasa con $Bel(x_t)$ cuando agregamos mediciones z_t ?
 - Como vimos en el ejemplo, **aumenta la certeza** !
- ¿ Qué pasa con $Bel(x_t)$ cuando agregamos una acción u_t ?
 - Acción efectuada por el robot
 - Acción efectuada por un agente externo
 - Tiempo
 - ... algo que cambie el estado del mundo
 - **Disminuye la certeza** !


Mediciones aumentan la certeza del robot, acciones la bajan!

Robótica Probabilística

- Queremos ver cómo cambia el mundo x producto de una “acción” u a partir de un mundo x' . Esto se demonina como **ACTION MODEL**

$$P(x|u, x')$$

- Ejemplo: robot avanza 1 [m] cada vez, hasta recorrer 10 [m]
 - Error ángulo: 5°
 - Error distancia: 0.05 [m]



Resumen

- Las probabilidades nos acompañarán el resto del curso
 - Movimientos no son exactos
 - Percepción no es exacta
 - Razonamiento debe incorporar la incerteza
- Regla de Bayes
 - No memorizar. Entender e interpretar.
- Filtros bayesianos
 - Bayes + Markov
 - Genérico, muy utilizado en la práctica

Bibliografía

- ***Probabilistic Robotics***, Thrun, S., Burgard, W., Fox, D.