

IIC2685 Robótica Móvil I – 2022

Capítulo 4.4

Mapping con Poses Conocidas

Profesor: Gabriel Sepúlveda V.
grsepulveda@ing.puc.cl

Agenda

- Entender para qué un robot necesita un mapa
- Fundamentos de creación de mapas dadas las poses

Mapping

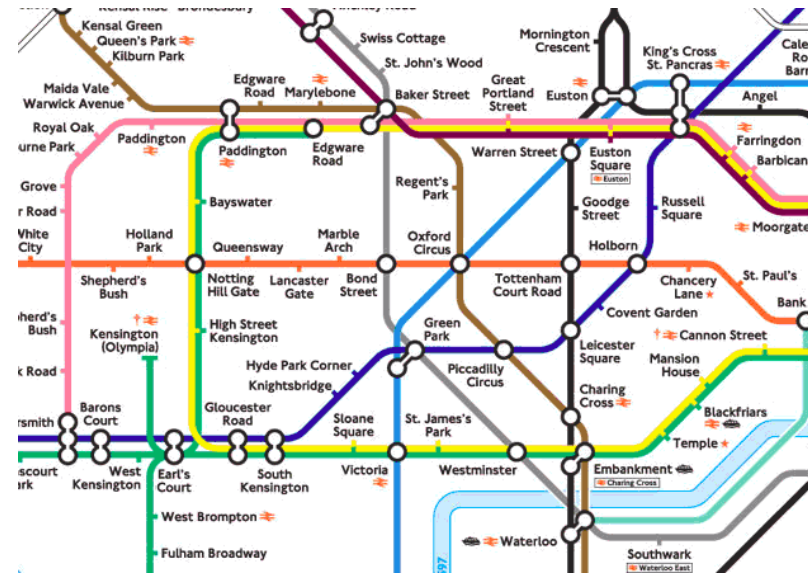
- ¿ Es realmente necesario un mapa ?
 - Insectos: sólo comportamientos reactivos
 - Animales “superiores”: comportamientos reactivos + **memoria**
- Robots
 - **Mapa es su memoria**
 - Comportamientos reactivos siguen siendo importantes, aunque conocer el mapa permite comportamientos **eficientes**
 - Robots exitosos usan el mapa para localización, planear rutas, planear actividades, etc.

Mapping

- Dos tipos de mapas típicos
 - Métricos: representación de espacios ocupados/desocupados (grid map)
 - Topológicos: basado en landmarks (mapa de conectividad)
- Nos enfocaremos en mapas métricos.



Métrico



Topológico

Problema general de mapping

- Recordemos las **Grandes Preguntas** de un robot móvil

¿Dónde estoy?

¿Para dónde voy?

¿Cómo llego?



Problema general de mapping

- Recordemos las **Grandes Preguntas** de un robot móvil

¿Dónde estoy?

¿Para dónde voy?

¿Cómo llego?




En todas las preguntas está involucrado el mapa (o memoria)!

Problema general de mapping

¿ Por qué es necesario elaborar técnicas *sofisticadas* de mapeo ?

Problema general de mapping


¿ Por qué es necesario elaborar técnicas *sofisticadas* de mapeo ?




Datos de Odometría

Problema general de mapping

¿ Por qué es necesario elaborar técnicas *sofisticadas* de mapeo ?



Datos de Odometría



Occupancy Grid Map

Occupancy Grid maps

- Mapa métrico, discretizado en celdas (por ejemplo, de 5 [cm] x 5 [cm])
- La estructura de grid es rígida
- Cada celda tiene tres estados: ocupada / desocupada / desconocido
- Por lo general se usa un sensor de barrido 2D (ej: LIDAR, sonar, etc.)



Mapping - definiciones

- Supondremos que nos movemos en un ambiente 2D (ej: TurtleBot), y que las poses $x_i = (x, y, \theta)_i$ son conocidas
- Formalización: dados los datos de el (los) sensor(es) z y las poses x

$$d = \{x_1, z_1, x_2, z_2, \dots, x_t, z_t\}$$

debemos calcular el mapa m “más probable”


$$m^* = \operatorname{argmax}_m P(m|d)$$

Occupancy Grid Maps - supuestos

- El área que corresponde a una celda puede estar *ocupada* o *desocupada*



- Cada celda es representada por una variable aleatoria binaria m_i
 - Celda ocupada : $p(m_i = \text{ocupada}) = p(m_i) = 1$
 - Celda desocupada : $p(m_i = \text{ocupada}) = p(m_i) = 0$
 - Celda desconocida : $p(m_i = \text{ocupada}) = p(m_i) = 0.5$



Occupancy Grid Maps - supuestos

- El mapa es la unión de todas las celdas. Cada una de ellas es estática (no cambia en el tiempo)

$$m = \{m_1, m_2, \dots, m_N\}$$

- Supondremos que los estados de las celdas son **condicionalmente independientes** dadas las observaciones y posiciones del robot

$$d = \{x_1, z_1, x_2, z_2, \dots, x_t, z_t\}$$

$$P(m|d) = \prod_{i=1}^N P(m_i|d)$$

Occupancy Grid Maps – derivación

- Queremos calcular: $p(m_i | z_{1:t}, x_{1:t})$

Occupancy Grid Maps – derivación

- Queremos calcular: $p(m_i|z_{1:t}, x_{1:t})$

$$p(m_i|z_{1:t}, x_{1:t}) \stackrel{\text{Bayes}}{=} \frac{p(z_t|m_i, z_{1:t-1}, x_{1:t}) \cdot p(m_i|z_{1:t-1}, x_{1:t})}{p(z_t|z_{1:t-1}, x_{1:t})}$$

Occupancy Grid Maps – derivación

- Queremos calcular: $p(m_i | z_{1:t}, x_{1:t})$

$$p(m_i | z_{1:t}, x_{1:t}) \stackrel{\text{Bayes}}{=} \frac{p(z_t | m_i, z_{1:t-1}, x_{1:t}) \cdot p(m_i | z_{1:t-1}, x_{1:t})}{p(z_t | z_{1:t-1}, x_{1:t})}$$

$$\stackrel{\text{Markov}}{=} \frac{p(z_t | m_i, x_t) \cdot p(m_i | z_{1:t-1}, x_{1:t-1})}{p(z_t | z_{1:t-1}, x_{1:t})}$$

Occupancy Grid Maps – derivación

- Queremos calcular: $p(m_i|z_{1:t}, x_{1:t})$

$$p(m_i|z_{1:t}, x_{1:t}) \stackrel{\text{Bayes}}{=} \frac{p(z_t|m_i, z_{1:t-1}, x_{1:t}) \cdot p(m_i|z_{1:t-1}, x_{1:t})}{p(z_t|z_{1:t-1}, x_{1:t})}$$

$$\stackrel{\text{Markov}}{=} \frac{p(z_t|m_i, x_t) \cdot p(m_i|z_{1:t-1}, x_{1:t-1})}{p(z_t|z_{1:t-1}, x_{1:t})}$$

$$\stackrel{\text{Bayes}}{=} \frac{p(m_i|z_t, x_t) \cdot p(z_t|x_t) \cdot p(m_i|z_{1:t-1}, x_{1:t-1})}{p(m_i|x_t) \cdot p(z_t|z_{1:t-1}, x_{1:t})}$$

Occupancy Grid Maps – derivación

- Queremos calcular: $p(m_i | z_{1:t}, x_{1:t})$

$$p(m_i | z_{1:t}, x_{1:t}) \stackrel{\text{Bayes}}{=} \frac{p(z_t | m_i, z_{1:t-1}, x_{1:t}) \cdot p(m_i | z_{1:t-1}, x_{1:t})}{p(z_t | z_{1:t-1}, x_{1:t})}$$

$$\stackrel{\text{Markov}}{=} \frac{p(z_t | m_i, x_t) \cdot p(m_i | z_{1:t-1}, x_{1:t-1})}{p(z_t | z_{1:t-1}, x_{1:t})}$$

$$\stackrel{\text{Bayes}}{=} \frac{p(m_i | z_t, x_t) \cdot p(z_t | x_t) \cdot p(m_i | z_{1:t-1}, x_{1:t-1})}{p(m_i | x_t) \cdot p(z_t | z_{1:t-1}, x_{1:t})}$$

$$\stackrel{\text{Independencia}}{=} \frac{p(m_i | z_t, x_t) \cdot p(z_t | x_t) \cdot p(m_i | z_{1:t-1}, x_{1:t-1})}{p(m_i) \cdot p(z_t | z_{1:t-1}, x_{1:t})}$$

Occupancy Grid Maps – derivación

- Para problemas de estados **binarios**, es conveniente expresar las probabilidades como **razón de probabilidades** (*odds ratio*):

$$\frac{p(x)}{p(\neg x)} = \frac{p(x)}{1 - p(x)}$$

- O bien, su versión logarítmica (*log odds ratio*)

$$l(x) = \log \left(\frac{p(x)}{1 - p(x)} \right)$$

- Esto evita truncado en 0 y 1, lo cual mejora estabilidad numérica
- Además, se cuenta con función inversa:

$$p(x) = 1 - \frac{1}{1 + e^{l(x)}}$$

Occupancy Grid Maps – derivación

- Según lo anterior tenemos:

$$p(m_i|z_{1:t}, x_{1:t}) = \frac{p(m_i|z_t, x_t) \cdot p(z_t|x_t) \cdot p(m_i|z_{1:t-1}, x_{1:t-1})}{p(m_i) \cdot p(z_t|z_{1:t-1}, x_{1:t})}$$

$$p(\neg m_i|z_{1:t}, x_{1:t}) = \frac{p(\neg m_i|z_t, x_t) \cdot p(z_t|x_t) \cdot p(\neg m_i|z_{1:t-1}, x_{1:t-1})}{p(\neg m_i) \cdot p(z_t|z_{1:t-1}, x_{1:t})}$$

- De lo cual obtenemos:

$$\frac{p(m_i|z_{1:t}, x_{1:t})}{p(\neg m_i|z_{1:t}, x_{1:t})} = \frac{\frac{p(m_i|z_t, x_t) \cdot \cancel{p(z_t|x_t)} \cdot p(m_i|z_{1:t-1}, x_{1:t-1})}{p(m_i) \cdot \cancel{p(z_t|z_{1:t-1}, x_{1:t})}}}{\frac{p(\neg m_i|z_t, x_t) \cdot \cancel{p(z_t|x_t)} \cdot p(\neg m_i|z_{1:t-1}, x_{1:t-1})}{p(\neg m_i) \cdot \cancel{p(z_t|z_{1:t-1}, x_{1:t})}}}$$

Occupancy Grid Maps – derivación

- Obteniendo finalmente:

$$\frac{p(m_i|z_{1:t}, x_{1:t})}{1 - p(m_i|z_{1:t}, x_{1:t})} = \underbrace{\frac{p(m_i|z_t, x_t)}{1 - p(m_i|z_t, x_t)}}_{\text{sensor inverso}} \cdot \underbrace{\frac{p(m_i|z_{1:t-1}, x_{1:t-1})}{1 - p(m_i|z_{1:t-1}, x_{1:t-1})}}_{\text{termino recursivo}} \cdot \underbrace{\frac{1 - p(m_i)}{p(m_i)}}_{\text{prior}^{-1}}$$

- Cuya versión logarítmica toma la forma de:

$$l(m_i|z_{1:t}, x_{1:t}) = \underbrace{l(m_i|z_t, x_t)}_{\text{sensor inverso}} + \underbrace{l(m_i|z_{1:t-1}, x_{1:t-1})}_{\text{termino recursivo}} - \underbrace{l(m_i)}_{\text{prior}}$$


Occupancy Grid Maps - derivación

- Con esta expresión, es posible definir el algoritmo de mapeo:

```
1:   Algorithm occupancy_grid_mapping( $\{l_{t-1,i}\}, x_t, z_t$ ):  
2:       for all cells  $m_i$  do  
3:           if  $m_i$  in perceptual field of  $z_t$  then  
4:                $l_{t,i} = l_{t-1,i} + \text{inverse\_sensor\_model}(m_i, x_t, z_t) - l_0$   
5:           else  
6:                $l_{t,i} = l_{t-1,i}$   
7:           endif  
8:       endfor  
9:       return  $\{l_{t,i}\}$ 
```


Occupancy Grid Maps - derivación

- Consideraciones geométricas para el Modelo de Sensor Inverso




Occupancy Grid Maps - derivación

- Consideraciones geométricas para el Modelo de Sensor Inverso




Occupancy Grid Maps - derivación

- Consideraciones geométricas para el Modelo de Sensor Inverso




Occupancy Grid Maps - derivación

- Consideraciones geométricas para el Modelo de Sensor Inverso




Occupancy Grid Maps - derivación

- Consideraciones geométricas para el Modelo de Sensor Inverso




Occupancy Grid Maps - derivación

- Consideraciones geométricas para el Modelo de Sensor Inverso




Occupancy Grid Maps - derivación

- Consideraciones geométricas para el Modelo de Sensor Inverso



Occupancy Grid Maps - derivación

- Consideraciones geométricas para el Modelo de Sensor Inverso



Occupancy Grid Maps - derivación


- Algoritmo *simple* para Modelo de Sensor Inverso

```
1:   Algorithm inverse_range_sensor_model( $i, x_t, z_t$ ):  
2:     Let  $x_i, y_i$  be the center-of-mass of  $m_i$   
3:      $r = \sqrt{(x_i - x)^2 + (y_i - y)^2}$   
4:      $\phi = \text{atan2}(y_i - y, x_i - x) - \theta$   
5:      $k = \text{argmin}_j |\phi - \theta_{j,\text{sens}}|$   
6:     if  $r > \min(z_{\text{max}}, z_t^k + \alpha/2)$  or  $|\phi - \theta_{k,\text{sens}}| > \beta/2$  then  
7:       return  $l_0$   
8:     if  $z_t^k < z_{\text{max}}$  and  $|r - z_t^k| < \alpha/2$   
9:       return  $l_{\text{occ}}$   
10:    if  $r \leq z_t^k$   
11:      return  $l_{\text{free}}$   
12:    endif
```

- α : grosor mínimo de obstáculos
- β : ángulo de apertura (cono de visión) de cada rayo del sensor
- l_0, l_{occ} y l_{free} : valores de ocupación en formato *log odds ratio*

Occupancy Grid Maps

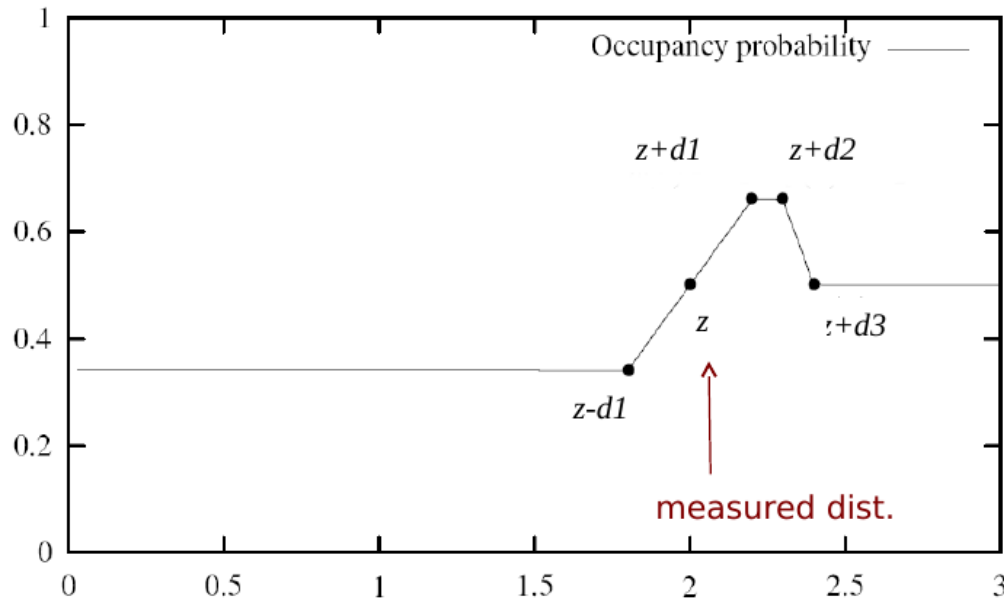
- “Perceptual field” del sensor
 - Depende de las características (ángulo de apertura de cada medición, distancia máxima)
 - Ej: Una lectura de un sonar tiene un ángulo amplio, por lo que una medición puede abarcar varias celdas




Occupancy Grid Maps

- Para una medición, el *inverse sensor model* debe considerar estas características
 - Intensidad del update lineal con relación a la distancia medida

Sonar




Laser



Occupancy Grid Maps

- Ángulo se ajusta a una distribución normal




Occupancy Grid Maps

- Ejemplo de mapa con Sonar




Occupancy Grid Maps

- Ejemplo de mapa con Lidar



Medición cruda



Occupancy Grid Map


Grid maps

Map Building



Seekur Jr. On-Board Camera

- Robot's trajectory
- Current Laser Scan



Resumen

- Luego de este largo recorrido por los fundamentos de Robótica Probabilística tenemos
 - Localización con mapa conocido
 - Mapeo con pose conocida

Resumen

- Luego de este largo recorrido por los fundamentos de Robótica Probabilística tenemos
 - Localización con mapa conocido
 - Mapeo con pose conocida
- ¿ Qué fue primero ?, ¿ el huevo o la gallina ?

Resumen

- Luego de este largo recorrido por los fundamentos de Robótica Probabilística tenemos
 - Localización con mapa conocido
 - Mapeo con pose conocida
- ¿ Qué fue primero ?, ¿ el huevo o la gallina ?
- ¿ Cómo calculamos el mapa sin pose conocida ?, ¿ como obtenermos la pose sin contar con un mapa ?

Resumen

- Luego de este largo recorrido por los fundamentos de Robótica Probabilística tenemos
 - Localización con mapa conocido
 - Mapeo con pose conocida
- ¿ Qué fue primero ?, ¿ el huevo o la gallina ?
- ¿ Cómo calculamos el mapa sin pose conocida ?, ¿ como obtenermos la pose sin contar con un mapa ?
- Para poder resolver este problema de forma práctica necesitamos obtener el mapa y la pose de forma simultánea

Resumen

- Luego de este largo recorrido por los fundamentos de Robótica Probabilística tenemos
 - Localización con mapa conocido
 - Mapeo con pose conocida
- ¿ Qué fue primero ?, ¿ el huevo o la gallina ?
- ¿ Cómo calculamos el mapa sin pose conocida ?, ¿ como obtenermos la pose sin contar con un mapa ?
- Para poder resolver este problema de forma práctica necesitamos obtener el mapa y la pose de forma simultánea
- En el año 1986, en la IEEE Robotics and Automation Conference, empieza a cobrar interés la idea de resolver ambos problemas de forma simultánea.

Resumen

- Luego de este largo recorrido por los fundamentos de Robótica Probabilística tenemos
 - Localización con mapa conocido
 - Mapeo con pose conocida
- ¿ Qué fue primero ?, ¿ el huevo o la gallina ?
- ¿ Cómo calculamos el mapa sin pose conocida ?, ¿ como obtenermos la pose sin contar con un mapa ?
- Para poder resolver este problema de forma práctica necesitamos obtener el mapa y la pose de forma simultánea
- En el año 1986, en la IEEE Robotics and Automation Conference, empieza a cobrar interés la idea de resolver ambos problemas de forma simultánea.
- En el año 1995, en el International Symposium on Robotics Research, se define la estructura general del problema y se acuña el término:

SLAM: Simultaneous Localization and Mapping

Resumen

- Vimos como generar un mapa métrico suponiendo **poses conocidas**.
- Siempre las celdas son tratadas en forma independiente, para generar un problema tratable.
- Mapas se suponen estáticos, aunque en la realidad no lo son.
- Cuando, además del mapa, las poses del robot son **desconocidas**, se agrega incertidumbre en x_t . Esto da lugar a un nuevo problema que requiere de **localización y mapeo de forma simultánea**.
- En el año 1986, en la IEEE Robotics and Automation Conference, empieza a cobrar interés la idea de resolver ambos problemas de forma simultánea.
- En el año 1995, en el International Symposium on Robotics Research, se define la estructura general del problema y se acuña el término:

SLAM: Simultaneous Localization and Mapping

Bibliografía

- ***Probabilistic Robotics***, Thrun, S., Burgard, W., Fox, D.